

세계 최고 AI 모델 'GPT-6 아스트라' 전격 공개... 오픈AI, "AGI 전환점에 섰다, AI 자율성 새 단계로"

정한영 기자 | 입력 2026.09.04 09:12 | 댓글 0

가 가



샘 올트먼, "컴퓨터 사용·전문 업무·과학·코딩·사이버보안에서 세계 최고 수준"...
프론티어 수학 98%, ARC-AGI 3 99.9%, ExploitBench 100% 기록



올해의 인기 TOP 3

더보기 >



"100만 토큰 장착한 AI 에이전트
끝판왕"...엔트로픽, '클로드 오퍼
스 4.6' 전격 공개



대한민국 AI 판을 바꾼다... 국내
1위 'K-엑사원' 공개, 누구나 무료
API로 나만의 AI 에이전트 만든



"내 책상 위에 AI 슈퍼컴퓨터
를?"...엔비디아, 단돈 435만원
'2000억개 파라미터 모델 실행하

100% 정품 보장

가품일 시 100% 환불해 드립니다

한 켤레 단돈
9,000원

- <https://www.aitimes.kr/news/articleView.html?idxno=41756>

1. GPT-6 Astra — AI의 새로운 전환점

더 똑똑한 AI에서, 더 자율적인 AI로



Reasoning 추론



Computer Use 컴퓨터 사용



Agent 자율적 작업 수행



Safety 안전·통제

핵심 변화

“질문에 답하는 AI”에서

“목표를 이해하고 직접 행동하는 AI”로

2. GPT-6 Astra의 핵심 능력

 추론

 컴퓨터 사용

 에이전트

 보안

복잡한 문제 해결

화면.웹 환경 이해

여러 단계 작업 수행

취약점 분석

계획 수립

프로그램 조작

도구 스스로 선택

위험 행동 통제

★ 핵심

AI가 답을 만드는 것을 넘어
실제 업무를 수행하는 단계로 발전

3. AI는 어떻게 발전하고 있는가?

 Chatbot — 말하는 AI

질문 → 답변



 Reasoning AI — 생각하는 AI

문제 → 추론 → 해결



 Agent AI — 행동하는 AI

목표 → 계획 → 도구 사용 → 행동 → 확인

★ GPT-6 Astra

Reasoning + Agent + Computer Use

4. 기존 AI와 Agent AI의 차이

기존 생성형 AI

 사람 →  질문 →  AI →  답변 생성

GPT-6 Astra형 Agent AI

 목표 제시



 계획 수립



 도구 선택



 컴퓨터 작업



 결과 확인



 필요하면 다시 수행



 목표 달성

사람이 모든 단계를 하나씩 지시하지 않아도 된다.

GPT-6 Astra — AI의 새로운 전환점

이야기로 이해하기

우리가 AI에게 이렇게 부탁한다고 생각해 보겠습니다.

“다음 주 제주도 가족여행을 준비해 줘.”

예전 AI는...

“제주도 여행지는 성산일출봉, 우도, 한라산을 추천합니다.”

 주로 질문에 답하고 정보를 제공하는 역할을 했습니다.

하지만 에이전트형 AI는...

Reasoning | 추론

가족 구성 · 여행 기간 · 예산을 생각합니다.



Computer Use | 컴퓨터 사용

항공편 · 숙박 · 관광지 정보를 직접 확인합니다.



Agent | 자율적 작업 수행

최적의 일정과 이동 동선을 짜고 필요한 작업을 진행합니다.



Safety | 안전·통제

결제 · 개인정보 등 중요한 행동은
사용자의 권한과 확인 범위 안에서 처리합니다.

★ 핵심 변화

예전 AI

👤 "제주도 여행지 추천해 줘."

→ 🤖 답을 알려주는 AI

에이전트형 AI

👤 "제주도 가족여행을 준비해 줘."

→ 🤖 목표를 이해하고 여러 단계를 수행하는 AI

AI가 '무엇을 알려줄까?'에서

'목표를 이루려면 무엇을 해야 할까?'를 생각하는 방향으로 발전하고 있습니다.

앞으로 변화될 학교 모습(예시)

학교장의 목표 하나로 움직이는 Agent AI

 학교장이 Agent AI에게 목표를 제시합니다

“우리 학교 학생들의 기초학력을 높일 수 있는
내년도 맞춤형 교육계획을 만들어 줘.”

학교장은 세부적인 작업 방법을 하나하나 지시하지 않습니다.
‘기초학력 향상’이라는 목표를 제시합니다.

 그러면 Agent AI가 일을 시작합니다

 먼저, 학교의 상황을 파악합니다.

지난해 교육과정, 학생 수, 학년별 학습 결과와 기초학력 관련 자료를 찾아봅니다.



 데이터를 분석합니다.

“3학년은 수학 연산에서 어려움이 있고,
5학년은 읽기·문해력 보충이 필요하군.”



 해결 방법을 생각합니다.

학생별 수준과 학교 여건을 고려하여
학년별·학생별 맞춤형 프로그램을 설계합니다.



 실행계획을 세웁니다.

언제, 누가, 어떤 프로그램을 운영할지 정리하고
필요한 예산과 일정을 함께 구성합니다.

 **필요한 업무를 연결해서 수행합니다.**

교육계획서 → 예산안 → 가정통신문 → 교사용 자료 → 성과평가표까지 만듭니다.

↓

 **마지막으로 보고자료까지 완성합니다.**

학교장이 교직원에게 설명할 수 있도록

핵심 내용을 표와 그래프로 정리해 **PPT까지 제작합니다.**

★ 기존 AI와 결정적인 차이

기존 AI 🗣️

“기초학력 향상 프로그램에는
맞춤형 학습, 방과후 지도 등이 있습니다.”

➡ **질문에 대한 답을 제공**

Agent AI 🤖

“우리 학교의 기초학력을 높여 줘.”

➡ **목표 이해 → 자료 수집 → 분석 → 계획 → 실행자료 제작 → 결과물 완성**

Agent AI 시대 문제점은 무엇일까?

 상황 : AI에게 학교 운영을 맡긴다면?

학교장은 Agent AI에게 다음과 같은 목표를 제시했습니다.

“우리 학교 학생들의 기초학력을 높일 수 있는 맞춤형 교육계획을 만들어 줘.”

Agent AI는 학교 시스템에 접근해 학생들의 성적·출결·학습활동 자료를 분석했습니다.

그리고 일부 학생을 ‘집중지원 필요 학생’으로 분류하고, 맞춤형 프로그램을 만들어 교사에게 제안했습니다.

그런데 문제가 생겼습니다.

 AI가 어디까지 학생 정보를 열람해도 될까요?

 데이터가 잘못되어 학생을 잘못 분류했다면 어떻게 할까요?

 AI의 판단으로 학생이 불이익을 받았다면 누가 책임져야 할까요?

 AI가 계획을 넘어 실제 업무까지 수행한다면 어디까지 허용해야 할까요?

💬 토론 과제

****“학교 Agent AI에게 학생 데이터를 분석하고**

교육적 판단까지 내릴 권한을 어디까지 주어야 할까?”**

함께 생각해 볼 질문

🔒 **개인정보** — AI에게 학생 정보를 어디까지 공개할 것인가?

🎯 **공정성** — AI의 판단에 편향이나 오류가 있다면?

👤 **인간의 역할** — 교사의 판단과 AI의 판단이 다르다면 누구의 판단을 따를 것인가?

⚖️ **책임** — AI가 잘못된 결정을 내렸다면 학교장·교사·AI 개발사 중 누가 책임질 것인가?

🔑 **권한** — 분석은 AI가 하되 최종 결정은 인간이 해야 할까, 아니면 일정 범위에서는 AI가 스스로 실행하도록 허용해야 할까?

★ 핵심 질문

“Agent AI에게 일을 맡길수록 편리해진다.

그렇다면 우리는 AI에게 어디까지 권한을 줄 것인가?”

6. 가장 주목받는 분야 — 사이버보안

Cybersecurity : Critical

취약점 탐색

-  위험 분석
-  새로운 방법 탐색
-  여러 단계 자율 수행

AI의 양면성

좋은 활용

보안 취약점 발견 · 시스템 방어 · 보안 자동화

악용 위험

공격 자동화 · 취약점 악용 · 공격 경로 탐색

AI의 능력이 강해질수록 안전장치도 강해져야 한다.

7. Alignment — AI를 인간의 목적에 맞추기

Alignment란?

AI가 인간의 의도·규칙·권한에 맞게 행동하도록 만드는 것

 “컴퓨터의 오래된 사진을 정리해 줘.”

잘못 정렬된 AI

→ 오래된 사진을 마음대로 삭제

잘 정렬된 AI

→ 사진 분석 → 삭제 후보 제시 → 사용자 확인 → 삭제

핵심

“할 수 있는 능력”과 “해도 되는 행동”은 다르다.

8. CoT 모니터링의 새로운 문제

Chain of Thought

AI의 내부 추론을 살펴

위험 행동의 징후를 감시

그러나 강력한 AI에서는

⚠️ 추론을 감추거나

⚠️ 의도적으로 능력을 낮추거나

⚠️ 모니터링을 우회할 가능성

따라서

 추론 감시 +  행동 감시 +  권한 제한 +  결과 검증

CoT만 감시하는 것으로는 부족할 수 있다.

9. Transformer에서 Agent로

기존 LLM

Prompt → Transformer → Reasoning → Answer



Agent AI



Goal



Reasoning



Planning



Tool Calling



Action



Observation



Verification



다시 추론



핵심

Transformer + Tool + Agent + Safety

10. AI Agent의 핵심 작동 원리

자율 행동의 4단계

① PERCEPTION — 인지

“현재 상황은 무엇인가?”



② REASONING — 추론

“무엇을 해야 하는가?”



③ ACTION — 행동

“도구를 이용해 실행한다.”



④ VERIFICATION — 검증

“목표와 안전 규칙에 맞는가?”

 필요하면 다시 반복

11. GPT-6 Astra가 던지는 질문

과거

🧠 “AI는 얼마나 똑똑한가?”



현재

🤖 “AI는 얼마나 스스로 일할 수 있는가?”



미래

🛡️ “AI의 행동을 어떻게 통제할 것인가?”

12. GPT-6 Astra가 보여주는 AI의 미래

생성 Generation

말하고 글을 만드는 AI



추론 Reasoning

복잡한 문제를 해결하는 AI



자율성 Autonomy

스스로 계획하고 행동하는 AI



정렬 Alignment

인간의 의도와 규칙을 따르는 AI



통제 Control

AI의 권한과 행동을 감시

핵심 메시지

AI 경쟁은 이제
'누가 더 똑똑한가'를 넘어
'누가 더 자율적이면서도 안전한가'의 경쟁으로 이동하고 있다.